本文为计算机视觉基金会（CVF）提供的 CVPR 论文开放获取版本。除本水印外，与录用版本完全一致；会议论文集的最终正式版本可在 IEEE Xplore 上获取。

SCConv：面向特征冗余的空间与通道重构卷积

Jiafeng Li[1]，Ying Wen[1]*，Lianghua He[2]
[1]华东师范大学通信与电子工程学院，中国上海
[2]同济大学计算机科学与技术系，中国上海

摘要　卷积神经网络（CNN）在各类计算机视觉任务中取得了卓越性能，但这是以巨大的计算资源开销为代价的，部分原因在于卷积层提取了冗余特征。近期工作要么压缩训练好的大规模模型，要么探索精心设计的轻量型模型。本文尝试利用特征间的空间与通道冗余来进行 CNN 压缩，提出一种高效的卷积模块，称为 SCConv（空间与通道重构卷积），以减少冗余计算并促进具有代表性的特征学习。所提出的 SCConv 由两个单元组成：空间重构单元（SRU）和通道重构单元（CRU）。SRU 采用分离—重构方法抑制空间冗余，而 CRU 采用分割—变换—融合策略削减通道冗余。此外，SCConv 是一个即插即用的架构单元，可直接替代各类卷积神经网络中的标准卷积。实验结果表明，嵌入 SCConv 的模型能够在显著降低复杂度和计算成本的同时，通过减少冗余特征获得更优性能。

1. 引言

近年来，卷积神经网络（CNN）凭借其获取具有代表性特征的能力，在计算机视觉任务中获得了广泛应用[24]。然而，这种成功严重依赖于密集的计算与存储资源，给其在资源受限环境中的高效部署带来了严峻挑战。因此，为应对这些挑战，人们探索了各类模型压缩策略与网络设计，以提升网络效率。

*通讯作者（邮箱：ywen@cs.ecnu.edu.cn）

效率[1, 2, 26]。前者包括网络剪枝、权重量化、低秩分解和知识蒸馏。具体而言，网络剪枝[17,22,30]是一种直接的方法，从已训练好的大模型中剪除无关紧要的神经元连接，使其更轻薄。权重量化[9]主要关注将网络权重从浮点型转换为整型，以节省计算资源。低秩分解[5]运用矩阵分解技术来估计信息性参数。知识蒸馏[11, 34]在训练良好的大教师网络指导下生成小型学生网络。这些压缩技术的共同点在于，它们都被视为后处理步骤，因此其性能通常受限于给定的初始模型；同时，在达到高压缩率时，这些方法的精度会急剧下降。网络设计是另一种替代途径，旨在降低稠密模型参数中的固有冗余，并进一步发展轻量型网络模型。例如，ResNet[10]和 DenseNet[14]利用高效的捷径连接改进网络拓扑，将所有先前的特征图连接起来以减少冗余参数。ResNeXt[31]用稀疏连接的分组卷积替代传统卷积，以降低通道间连接性。Xception[4]、MobileNet[12]和 MobileNeXt[35]等网络将标准卷积解耦为深度卷积和逐点卷积，进一步降低通道间的连接密度。MicroNet[19]通过将稀疏连接融入卷积，采用微分解卷积来处理极低 FLOPs 的情形。此外，EfficientNet[27]学习自动搜索最优网络架构，以降低稠密模型参数中的冗余。再者，在 CNN 架构设计中，瓶颈结构被广泛采用，其中 3×3 卷积层占据了模型参数和 FLOPs 的大部分。因此，各种高效卷积操作

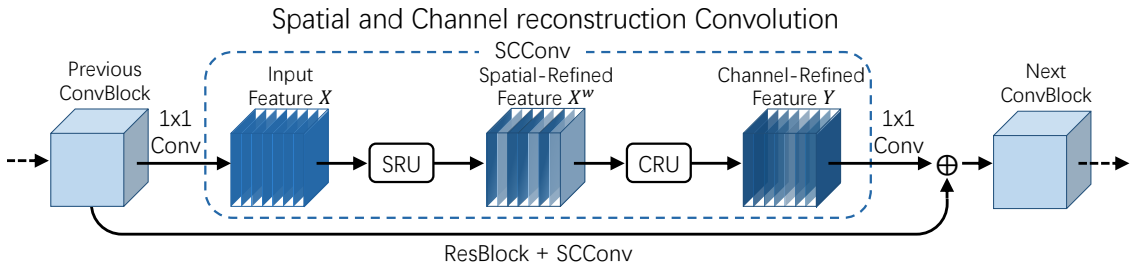


图1. 结合空间重构单元（SRU）与通道重构单元（CRU）的 SCConv 架构。本图展示了 SCConv 模块在 ResBlock 中的具体位置。

（如分组卷积（GWC）、深度卷积（DWC）和逐点卷积（PWC）——标准卷积的一种变体）被提出以替代现有的昂贵卷积运算。GWC 最早出现于 AlexNet[16]，可视为一种稀疏卷积连接方法，每个输出通道仅连接到某一特定的输入通道组。DWC[13]通过让每个通道单独与卷积核卷积且通道间无交互来提升效率。PWC 用于保持信息在通道间流动，并通过减少卷积核数量实现降维。这些运算在稀疏连接方面相似，并在参数量和 FLOPs 上具有优势，说明通道维度的冗余可以被合理削减。因此，人们提出了多种卷积运算来探索冗余削减。例如，MobileNet[12]引入利用 DWC 和 PWC 过滤特征的倒残差块，在减少参数量的同时加速训练。ShuffleNet[33]借助逐点分组卷积和通道混洗操作来改善不同通道组间的信息流。HetConv[25]设计异构卷积滤波器，在单个滤波器中同时包含 3×3 卷积核和 1×1 卷积核以提取特征。TiedBlockConv[28]在相等的通道块上共享同一卷积滤波器，以在单个滤波器内产生多个响应。SPConv[32]将输入通道分为两组进行不同处理，但在提取内部信息时需要较大的计算量。GhostNet[8]考虑特征图之间的冗余，采用 DWC 等廉价运算来学习冗余特征。SilmConv[23]采用减少特征通道数并翻转权重的操作来降低特征冗余。此外，与通道冗余正交，OctConv[3]提出八度卷积，将卷积滤波器分离为高频和低频分量，对后者以低分辨率处理以缓解空间冗余，从而在保持参数量不变的同时减少计算量。

上述所有前期研究已证明，深度神经网络中确实存在大量冗余，不仅存在于稠密模型参数中，也存在于特征图的空间和通道维度中。然而，上述方法要么聚焦于削减通道维度冗余，要么聚焦于空间维度冗余，使得网络仍然受困于特征冗余问题。本文与先前工作不同，设计了一个两步流程来挖掘中间特征图的冗余，目标是在不损失性能的前提下减少参数量和计算量。为此，我们提出一种新颖的 CNN 压缩方法，在卷积层中联合削减空间和通道冗余，称为 SCConv（空间与通道重构卷积），它由空间重构单元（SRU）和通道重构单元（CRU）两个单元组成。所提出的 SCConv 模块无需额外修改即可嵌入各种架构，旨在高效地限制特征冗余。该模块不仅削减模型参数量和 FLOPs，还增强了特征表示能力。我们的贡献总结如下：

- 我们提出一种空间重构单元，称为 SRU，它基于权重分离冗余特征并对其进行重构，以抑制空间维度冗余并增强特征表示。
- 我们提出一种通道重构单元，称为 CRU，它采用分割—变换—融合策略，在削减通道维度冗余的同时降低计算成本和存储开销。
- 我们设计了一个名为 SCConv 的即插即用操作，以串行方式结合 SRU 和 CRU，替代标准卷积以在多种骨干 CNN 上运行。实验表明，SCConv 能够在大幅节省计算负载的同时，提升模型在挑战性任务上的性能。

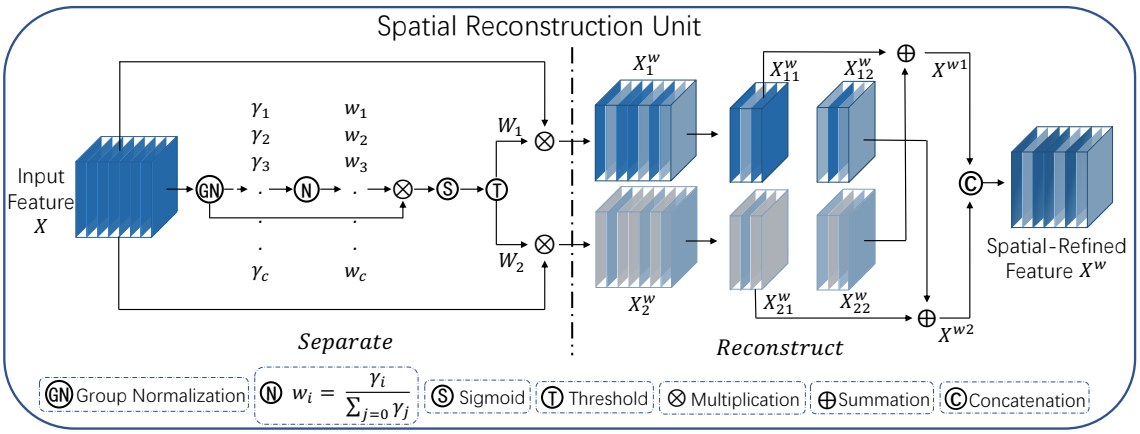


图2. 空间重构单元的架构。

2. 方法　本节介绍所提出的 SCConv，如图1所示，它由空间重构单元（SRU）和通道重构单元（CRU）两个单元按串行方式构成。具体地，对于瓶颈残差块中的中间输入特征 X，我们首先通过 SRU 操作得到空间精修特征 X^w，随后利用 CRU 操作得到通道精修特征 Y。我们在 SCConv 模块中挖掘特征间的空间与通道冗余，该模块可无缝集成到任意 CNN 架构中，以削减中间特征图的冗余并增强 CNN 的特征表示。

2.1. 面向空间冗余的 **SRU**　为挖掘特征的空间冗余，我们引入空间重构单元（SRU），如图2所示，它采用分离—重构操作。分离操作旨在将信息性特征图与对应于空间内容的弱信息性特征图分离开来。我们利用组归一化（GN）[29]层中的缩放因子来评估不同特征图的信息性内容。具体地，给定中间特征图 $X \in \mathbb{R}^{N\times C\times H\times W}$，其中 N 为批次轴、C 为通道轴、H 和 W 为空间高度和宽度轴。我们首先对输入特征 X 标准化：减去均值 μ 并除以标准差 σ，如下所示：

$$X_{out} = GN(X) = \gamma\frac{X-\mu}{\sqrt{\sigma^2+\varepsilon}} + \beta \qquad (1)$$

其中 μ 和 σ 分别为 X 的均值和标准差，ε 是为除法稳定性而加入的小正常数，γ 和 β 为可训练的仿射变换参数。

注意，我们利用 GN 层中可训练的参数 $\gamma \in \mathbb{R}^C$ 来衡量每个批次和通道的空间像素方差。更丰富的空间信息反映出空间像素更大的变化，从而对应更大的 γ。归一化的相关权重 $W_\gamma \in \mathbb{R}^C$ 由公式 2 得到，它表明了不同特征图的重要性。

$$W_\gamma = \{w_i\} = \frac{\gamma_i}{\sum_{j=1}^{C}\gamma_j},\ i,j = 1,2,\cdots,C \qquad (2)$$

随后，由 W_γ 重加权的特征图权重经 sigmoid 函数映射到 (0,1) 区间，并由一个阈值进行门控。我们将高于阈值的权重置为 1，得到信息性权重 W_1；将其余权重置为 0，得到非信息性权重 W_2（实验中阈值设为 0.5）。获取 W 的整个过程可由公式 3 表示。

最后，我们分别用 W_1 和 W_2 乘以输入特征 X，得到两个加权特征：信息性特征 X^{w_1} 和弱信息性特征 X^{w_2}。由此我们成功地将输入特征分离为两部分：X^{w_1} 具有信息丰富且富有表现力的空间内容，而 X^{w_2} 几乎不含信息，被视为冗余。为削减空间冗余，我们进一步提出重构操作，将信息丰富的特征与弱信息特征相加，以生成信息更丰富的特征并节省空间。我们并非直接将两部分相加，而是采用交叉重构操作，充分结合这两个加权后的不同信息性特征，并增强它们之间的信息流。之后，我们将交叉重构得到的特征 X^{w1} 和 X^{w2} 拼接，得到空间精修特征图 X^w。重构的整个过程

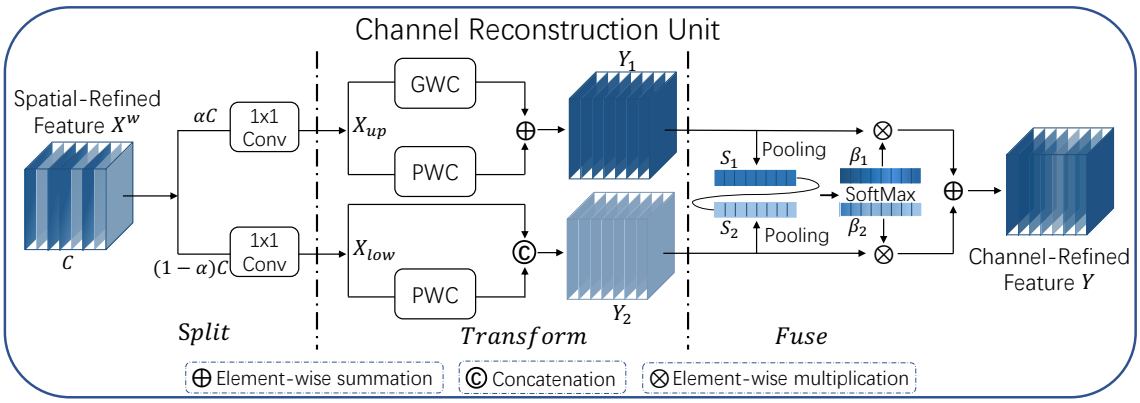


图3. 通道重构单元的架构。

可表示为：

$$\begin{cases} X_1^w = W_1 \otimes X, \\ X_2^w = W_2 \otimes X, \\ X_{11}^w \oplus X_{22}^w = X^{w1}, \\ X_{21}^w \oplus X_{12}^w = X^{w2}, \\ X^{w1} \cup X^{w2} = X^w. \end{cases} \tag{4}$$

其中 ⊗ 为逐元素乘法，⊕ 为逐元素加法，∪ 为拼接。在对中间输入特征 X 施加 SRU 之后，我们不仅将信息性特征与弱信息特征分离，还对其进行重构，以增强代表性特征并抑制空间维度的冗余特征。尽管如此，空间精修特征图 X^w 在通道维度上仍然存在冗余。

2.2. 面向通道冗余的 CRU　为挖掘特征的通道冗余，我们引入通道重构单元（CRU），如图3所示，它采用分割—变换—融合策略。通常，我们使用重复的标准 k×k 卷积提取特征，导致沿通道维度产生一些相对冗余的特征图。设 Mˆk ∈ ℝˆ(c×k×k) 为 k×k 卷积核，X, Y ∈ ℝˆ(c×h×w) 分别为输入和卷积输出特征。标准卷积[1]可定义为 Y = Mˆk X。具体地，我们用 CRU 替代标准卷积，它通过分割（Split）、变换（Transform）和融合（Fuse）三个算子实现。对于给定的空间精修特征 X^w ∈ ℝˆ(c×h×w)，分割：我们首先将 X^w 的通道分为两部分，分别为 αC 个通道和 (1−α)C 个通道，如图3的分割部分所示，其中 0 ≤ α ≤ 1 为分割比例。随后，我们进一步利用 1×1 卷积来

[1]为简洁起见，我们省略偏置项。

挤压特征图的通道以提升计算效率。这里我们引入挤压比例 r 来控制特征通道，以平衡 CRU 的计算成本（实验中 r = 2 为典型设置）。在分割和挤压操作之后，我们将空间精修特征 X^w 分为上支路 X_up 和下支路 X_low。X_up 被送入上变换阶段，充当"丰富特征提取器"。我们采用高效卷积运算（即 GWC 和 PWC）替代昂贵的标准 k×k 卷积，以提取高层代表性信息并降低计算成本。由于稀疏卷积连接，GWC 减少了参数量和计算量，但切断了通道组之间的信息流；而 PWC 则弥补了信息损失，并促进信息在特征通道间流动。因此，我们在同一 X_up 上执行 k×k GWC（实验中分组大小 g = 2）和 1×1 PWC 运算。之后，我们将输出求和，形成合并的代表性特征图 Y_1，如图3的变换部分所示。上变换阶段可表示为：

$$Y_1 = M^G X_{up} + M^{P_1} X_{up} \tag{5}$$

其中 MˆG ∈ ℝˆ{αC/r × k×k×c}、Mˆ{P1} ∈ ℝˆ{αC/r × 1×1×c} 是 GWC 和 PWC 的可学习权重矩阵，X_up ∈ ℝˆ{αC/r × h×w}、Y_1 ∈ ℝˆ{c×h×w} 分别为上支路输入和输出特征图。简言之，上变换阶段在同一特征图 X_up 上结合 GWC 和 PWC，以较低的计算成本提取丰富的代表性特征 Y_1。X_low 被送入下变换阶段，我们在其上执行廉价的 1×1 PWC 运算，生成具有浅层细节的特征图，作为丰富特征提取器的补充。此外，我们复用特征 X_low 以额外获得更多特征图而不增加成本。最后，我们

将生成的特征与复用的特征拼接，形成下支路的输出 Y_2，如下所示：

$$Y_2 = M^{P_2}\ X_{low} \cup X_{low} \tag{6}$$

其中 M^(P2) ∈ ℝ^((1−α)C/r × 1×1×(1−α)C) 是 PWC 的可学习权重矩阵，∪ 为拼接运算，X_low ∈ ℝ^((1−α)C/r× h×w)、Y_2 ∈ ℝ^(c×h×w) 分别为下支路输入和输出特征图。换言之，下变换阶段复用先前的特征 X_low，并利用廉价的 1×1 PWC 获得带有补充细节信息的特征 Y_2。

融合：在完成变换之后，我们并非直接拼接或相加两类特征，而是采用简化的 SKNet 方法[18]，自适应地融合来自上、下变换阶段的输出特征 Y_1 和 Y_2，如图3的融合部分所示。我们首先施加全局平均池化（Pooling），以逐通道统计量 S_m ∈ ℝ^(c×1×1) 收集全局空间信息，其计算方式为：

$$S_m = Pooling(Y_m) = \frac{1}{H \times W} \sum_{i=1}^{H} \sum_{j=1}^{W} Y_c(i,j),\ m = 1, 2 \tag{7}$$

接下来，我们将上、下两路全局通道描述子 S_1、S_2 堆叠在一起，并使用逐通道软注意力操作生成特征重要性向量 β_1、β_2 ∈ ℝ^c，如下所示：

$$^{1} \quad \overline{e^{s_1} + e^{s_2}} \quad ^{2} \quad \overline{e^{s_1} + e^{s_2}} \quad ^{1} \quad ^{2}$$

最后，在特征重要性向量 β_1、β_2 的引导下，通过以逐通道方式合并上支路特征 Y_1 和下支路特征 Y_2，即可得到通道精修特征 Y，如下所示：

简言之，我们采用 CRU，利用分割—变换—融合策略，进一步沿通道维度削减空间精修特征图 X^w 的冗余。此外，CRU 通过轻量卷积运算提取丰富的代表性特征，同时以廉价运算和特征复用方案处理冗余特征。总体而言，CRU 既可单独使用，也可与 SRU 操作结合使用。通过将 SRU 与 CRU 按串行方式排列，即构建出所提出的 SCConv，它高效且能够替代标准卷积运算。

2.3. 复杂度分析　我们的 SCConv 被设计为一个即插即用模块，可方便地嵌入各种已有的精心设计的神经架构中，以减少计算和存储成本。在 SCConv 模块中，所有参数都集中在变换阶段。因此我们分析理论存储占用的削减。标准卷积 Y = M^k X 的参数量可计算为：

$$P_s = k\ \times\ k \times\ C_1 \times\ C_2 = k^2 C_1 C_2 \tag{10}$$

其中 k 为卷积核大小，C_1 和 C_2 分别为输入和输出特征通道数。所提出的 SCConv 模块的参数量由下式给出：

$$\begin{aligned} &\overline{\qquad} \qquad \overline{\qquad} \quad \overline{\qquad} \\ &+ 1 \times 1 \times \frac{\alpha C_1}{r} \times C_2 + (1-\alpha)\, C_1 \times \frac{(1-\alpha)C_1}{r} \\ &+ 1 \times 1 \times \frac{(1-\alpha)C_1}{r} \times \left(C_2 - \frac{1-\alpha}{r} C_1 \right) \end{aligned} \tag{11}$$

其中 α 为分割比例，r 为挤压比例，g 为 GWC 运算的分组大小，C_1 和 C_2 分别为输入和输出特征通道数。这里我们给出对比以展示所提出 SCConv 的性能。实验中，一般参数设置为 α＝½、r = 2、g = 2、k_= 3、C_1 = C_2 = C，参数量可减少约 5 倍（P_s/P_sc ≈ 5），同时模型性能优于标准卷积。

3. 实验　为评估所提出 SCConv 的有效性，本节仅将广泛使用的 3×3 卷积核替换为 SCConv 模块，在图像分类和目标检测上开展一系列实验。图像分类基准包括 CIFAR-10[15]、CIFAR-100[15]和 ImageNet-1K[16]。目标检测基准包括 PASCAL VOC[6]和 MS COCO[21]。图像分类以 Top-1 准确率作为评价指标，目标检测以平均精度均值（mAP）衡量精度。为公平对比，每个实验中的所有模型（包括重新实现的基线和配备 SCConv 的模型）均在 2 块 NVIDIA Tesla V100 GPU 上从零开始训练，采用默认的数据增强和训练策略，不使用其他技巧。每个实验中，我们以相同配置训练多次以消除波动影响，并报告结果的中位数。

3.1. 实验设置　数据集。CIFAR 数据集（包括 CIFAR-10 和 CIFAR-100）由 5 万张训练图像和 1 万张验证图像组成，分别划分为 10 类和 100 类

ImageNet-1K 数据集是一个大规模图像分类数据集，包含来自 1000 个类别的 128 万张训练图像与 5 万张验证图像。PASCAL VOC 数据集共有 20 个类别，包含 2.2 万余张训练图像与 5 千张验证图像。MS COCO 数据集分为 80 个类别，包含 11.8 万余张训练图像与 5 千张验证图像。

训练与推理。 1) 对于 CIFAR-10 与 CIFAR-100，我们沿用文献 [10] 中类似的训练方案。网络使用 SGD 优化器训练 200 个轮次，权重衰减为 5×10^{-4}，动量为 0.9。学习率初始化为 0.05，并在第 100 和第 150 个轮次衰减为原来的 0.1。单张 GPU 上的 mini-batch 大小为 128。此外，根据不同的网络结构，对 ResNet、WideResNet、ResNeXt 将 (h, w) 设为 (8, 8)，对 DenseNet 设为 (4, 4)。2) 对于 ImageNet-1K 数据集，我们遵循标准做法，采用随机裁剪至 224×224 像素进行数据增强。使用 SGD，动量为 0.9，权重衰减为 1×10^{-4}。初始学习率设为 0.1，每 30 个轮次除以 10，共训练 100 个轮次。3) 对于 PASCAL VOC 数据集，使用 SGD 优化器，batch size 设为 32。初始学习率设为 0.1，并进行 500 次迭代的 warmup。共训练 2 万次迭代，在 1 万和 1.8 万次迭代时将学习率乘以 0.1。4) 对于 MS COCO 数据集，使用 SGD 优化器，初始学习率设为 0.1，batch size 设为 16。总迭代次数设为 18 万，并在 12 万和 16 万次迭代时将学习率除以 10。

3.2. 消融实验

本节中，我们开展消融实验，以考察所提出 SCConv 模块中不同组件的相对有效性。我们选择 ResNet50 作为基线网络，将其中标准 3×3 卷积替换为 SCConv，从而在 CIFAR-100 上进行以下消融实验。

SRU 与 CRU。 我们的 SCConv 模块包含一个空间重构单元（SRU）和一个通道重构单元（CRU）。首先，我们仅在 ResNet50 上单独施加 SRU 或 CRU，以考察单个单元的效率。如表 1 所示，仅嵌入 SRU（ResNet50＋S）在 FLOPs 不额外增加的情况下取得近 1% 的提升；而仅嵌入 CRU（ResNet50＋C）可节省 38% 的参数量与 FLOPs，同时 Top-1 精度提升 0.8%。结果表明，嵌入单个单元即可显著提升精度。此外，我们比较了三种排列 SRU 与 CRU 的方式：顺序空间-通道（S＋C）、顺序通道-空间（C＋S）以及两个单元并行使用（C&S）。我们发现，先空间后通道的顺序（S＋C）取得了最佳精度

表 1. 在 CIFAR-100 数据集上 SRU 与 CRU 不同组合方式的实验结果。（S、C 分别为 SRU 与 CRU 的缩写）

Description	Params	FLOPs	Top-1ACC(%)
ResNet50	23.71M	1.30G	78.60
ResNet50 + S	23.53M	1.30G	79.59
ResNet50 + C	14.74M	843.81M	79.21
ResNet50 + C & S	14.74M	843.81M	79.26
ResNet50 + C + S	14.74M	843.81M	79.54
ResNet50 + S + C	14.74M	843.81M	79.89

，优于其他组合方式。因此，我们采用先空间后通道的顺序组合（S＋C）策略来构建本文的 SCConv，以进一步提升模型性能。

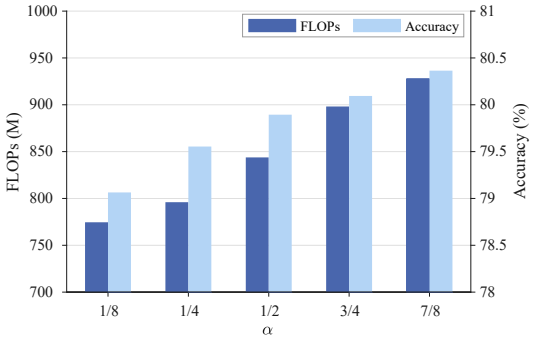


图 4. 在嵌入 SCConv 的 ResNet50 中，不同分割比例 α 下 CIFAR-100 上 FLOPs 与精度的权衡关系。

分割比例 α 的分析。 为探究 CRU 模块中不同分割比例 α 的影响，我们将分割比例从 1/8 逐渐变化到 7/8，以比较 CIFAR-100 上精度与 FLOPs 的关系。如图 4 所示，嵌入 SCConv 的 ResNet50 的精度随分割比例 α 的增大而上升。α 越大，表示模型在 CRU 的变换阶段能获取更丰富的特征信息，从而提升模型的整体性能。当 $\alpha=1/2$ 时，整个网络取得最佳的 FLOPs-精度权衡。因此，在后续实验中我们为 SCConv 采用最优分割比例 $\alpha=1/2$，以在性能与效率之间取得更好的权衡。

可视化。 为探究所提出 SRU 方法的特征表示，我们在图 5 中可视化了原始 ResNet50 与嵌入 SRU 的 ResNet50 第一阶段的特征图。可以观察到，与原始 ResNet50 相比，嵌入 SRU 的 ResNet50 特征中的模式更为丰富：冗余特征被削弱，同时具有代表性的特征得到增强与多样化。该可视化表明

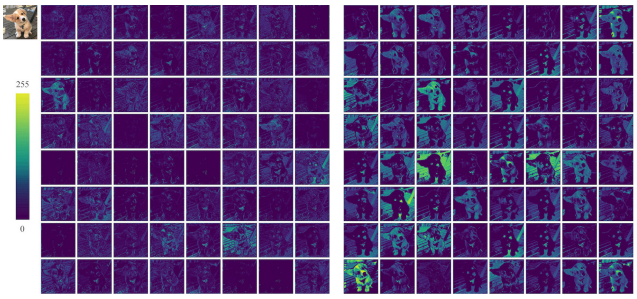


图 5. 左：原始 ResNet50 第一阶段的特征；右：嵌入 SRU 的 ResNet50 第一阶段的特征。

，SRU 能够生成具有代表性且更具表达力的特征。

3.3. CIFAR 上的图像分类

在研究了所提出 SCConv 模块用于高效特征学习的结构之后，我们继续在各种基线模型上评估嵌入 SCConv 的架构，并进一步在 CIFAR-10 与 CIFAR-100 数据集上，就分类精度、参数量和 FLOPs 与现有 SOTA 方法进行对比。相关的 SOTA 方法包括 OctConv [3]、GhostNet [8]、SPConv [32]、SlimConv [23]、TiedConv [28]。所有实验均通过将原始卷积层替换为相应的卷积方法来进行。

如表 2 所示，在所有情形下，我们嵌入 SCConv 的模型在精度上均优于先前的网络。对于 ResNet-56 模型，SCConv-R56 仅需对应 ResNet56 的 62.7% 参数量与 FLOPs，却在两个数据集上均带来超过 1% 的精度提升。对于 ResNet-50 模型，在 CIFAR-10 与 CIFAR-100 上，SCConv-R50 相比对应 ResNet50 取得更优精度（近 1% 和 1.3%），同时减少约 37% 的参数量和 34% 的 FLOPs。此外，SCConv-R50 与 SlimConv-R50 计算成本相同，却带来更高（超过 1%）的精度提升。为展示所提方法的通用性，我们将 SCConv 及其他 SOTA 方法应用于 ResNeXt-29、WideResNet-28 和 DenseNet-121。可以观察到，在计算量相当的情况下，嵌入 SCConv 的模型仍优于其他方法。例如，SCConv-RX29 取得超过 2.3% 的精度提升，而计算量与 GhostNet-RX29 相当；SCConv-WRN28 比 SlimConv-WRN28 取得更优精度（近 1.3%），同时将参数量和 FLOPs 分别节省 11.7% 和 15.5%。

3.4. ImageNet 上的图像分类

我们在 ImageNet-1K 数据集上对 ResNet50 进行实验，将我们方法的性能

表 2. 在 CIFAR-10 与 CIFAR-100 数据集上，常见 CNN 架构与 SOTA 方法在 Top-1 精度、参数量与 FLOPs 上的对比。

Network Architecture	FLOPs	Params	CIFAR-10 ACC(%)	CIFAR-100 ACC(%)
ResNet56 (R56)	126.84M	0.86M	93.27	71.50
OctConv-R56 (α=1/2)	126.84M	0.62M	93.11	70.93
SPConv-R56 (α=1/2)	87.95M	0.58M	93.49	71.51
GhostNet-R56 (s=2)	**68.35M**	**0.45M**	92.35	70.42
SlimConv-R56 (k=1)	88.82M	0.60M	93.51	71.71
TiedConv-R56 (b=2)	94.99M	0.54M	92.87	71.10
SCConv-R56 (Ours)	79.55M	0.52M	**94.12**	**72.56**
ResNet50 (R50)	1.30G	23.52M	95.09	78.60
OctConv-R50 (α=1/2)	727.26M	23.52M	95.25	78.91
GhostNet-R50 (s=2)	**632.45M**	**14.56M**	94.30	77.54
SlimConv-R50 (k=4/3)	853.50M	14.83M	95.05	78.85
SPConv-R50 (α=1/2)	972.31M	16.14M	95.32	79.23
SlimConv-R50 (k=1)	942.38M	16.78M	95.35	79.26
TiedConv-R50 (b=2)	998.78M	15.03M	95.44	79.52
SCConv-R50 (Ours)	831.18M	14.69M	**95.92**	**79.89**
ResNeXt-29 (RX29)	4.55G	28.27M	95.68	81.54
GhostNet-RX29 (s=2)	3.60G	**22.22M**	95.14	80.23
SPConv-RX29 (α=1/2)	4.79G	31.17M	96.03	81.76
SlimConv-RX29 (k=4/3)	4.38G	28.24M	95.85	81.93
TiedConv-RX29 (b=2)	5.96G	24.67M	95.66	81.32
SCConv-RX29 (Ours)	**3.57G**	22.31M	**96.20**	**82.56**
WideResNet-28 (WRN28)	5.96G	36.55M	95.21	79.40
GhostNet-WRN28 (s=2)	3.98G	22.12M	95.25	79.27
SPConv-WRN28 (α=1/2)	4.16G	24.20M	95.37	80.25
SlimConv-WRN28 (k=1)	4.25G	25.00M	95.43	79.52
TiedConv-WRN28 (b=2)	4.54G	22.03M	95.48	78.61
SCConv-WRN28 (Ours)	**3.75G**	**21.12M**	**95.64**	**80.83**
DenseNet-121 (D121)	898.23M	7.05M	95.09	79.43
GhostNet-D121 (s=2)	**517.36M**	**5.04M**	93.96	78.51
SPConv-D121 (α=1/2)	641.54M	5.69M	95.15	79.64
SlimConv-D121 (k=1)	670.21M	5.97M	94.63	78.90
TiedConv-D121 (b=2)	695.68M	5.45M	95.23	79.73
SCConv-D121 (Ours)	594.34M	5.45M	**95.37**	**80.24**

与近期 SOTA 方法进行比较，包括 OctConv [3]、SPConv [32]、GhostNet [8]、SlimConv [23]、PfLayer [7]、TiedConv [28] 等。注意，我们仅将瓶颈处的 3×3 卷积替换为相应的卷积方法。如表 3 所示，我们的 SCConv-R50（α=1/2）相比 ResNet50 模型可实现 34.4% 的计算量减少，并带来 0.26% 的精度提升。当进一步将分割比例 α 增大到 3/4 时，我们的方法在精度增长上优于所有其他最先进方法。例如，SCConv-R50（α=3/4）取得超过 0.6% 的精度提升，而计算量与 PfLayer-R50（max）相当。此外，SCConv-R50（α=1/2）在计算量相当的情况下，优于 SlimConv-R50（k=4/3）。为进一步证明 SCConv 的有效性，我们将其嵌入深度模型 ResNet101。在仅约 62% 计算成本下，我们的 SCConv-R101 相比基线模型带来 0.68% 的精度提升。此外，为便于比较，我们选取若干最先进方法绘制 FLOPs 与 Top-1 精度

表 3. ImageNet-1K 数据集上的图像分类结果。

Network Architecture	FLOPs(G)	Params(M)	Top-1 (%)
ResNet50 (R50) (Baseline)	4.09	25.56	76.15
Versatile-R50 (NIPS2018)	**1.80**	18.7	75.50
GhostNet-R50_s=2 (CVPR2020)	2.15	13.95	75.18
SlimConv-R50_k=8/3 (TIP2021)	1.88	**12.10**	75.32
SPConv-R50_α=1/2 (IJCAI2020)	2.97	18.34	76.26
OctConv-R50_α=1/2 (CVPR2020)	2.40	25.56	76.34
SlimConv-R50_k=4/3 (TIP2021)	2.65	16.76	76.12
PfLayer-R50_max (ICLR2022)	2.90	18.00	76.15
SlimConv-R50_k=1 (TIP2021)	3.00	18.81	76.32
TiedConv-R50_b=2 (AAAI2021)	3.19	17.07	76.04
SCConv-R50_α=1/2	2.70	16.78	76.41
SCConv-R50_α=3/4	2.87	17.69	**76.79**
ResNet_101(R101)(Baseline)	7.83	44.55	77.25
SCConv-R101	**4.90**	**28.00**	**77.93**

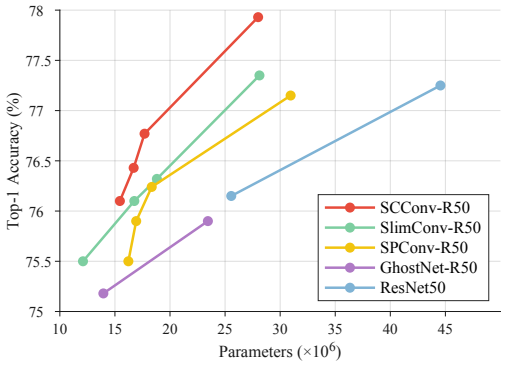


图 6. ImageNet 上 ResNet50 的 Top-1 精度与 FLOPs 关系。

的曲线。从图 6 的整体来看，我们所提出模型的曲线位于所有其他方法（包括 ResNet、GhostNet、SP-ResNet 和 SlimConv）之上。这表明我们的模型以更低的计算成本取得更高的精度；在相同性能下，嵌入 SCConv 的模型比其他模型更为紧凑。

3.5. 目标检测

为进一步评估 SCConv 的泛化能力，我们在两个数据集上进行目标检测任务的实验。采用单阶段的 RetinaNet [20] 作为检测框架。我们以 ResNet-50、ResNet-101 为主干网络，并将嵌入 SCConv 的模型作为主干特征提取器的即插即用替换。

表 4. PASCAL VOC 2007 与 2012 数据集上的目标检测实验。

Backbone	Params(M)/FLOPs(G)	AP@.5	AP@.75	mAP@[.5,.95]
ResNet50(R50)	25.56/63.09	77.89	55.31	52.26
SPConv-R50	19.76/49.23	78.05	55.47	52.48
SlimConv-R50	18.81/47.12	77.96	55.38	52.42
SCConv-R50	**16.78/41.36**	**78.68**	**56.26**	**53.16**
ResNet101(R101)	44.55/121.3	79.23	56.31	53.32
SCConv-R101	**27.90/75.26**	**80.36**	**57.05**	**54.12**

表 5. MS COCO val2017 上的目标检测结果。

Backbone	Params(M)/FLOPs(G)	AP@.5	AP@.75	mAP@[.5, .95]
ResNet50(R50)	25.56/63.09	54.2	37.4	35.2
SPConv-R50	19.76/49.23	54.5	37.6	35.3
SlimConv-R50	18.81/47.12	54.0	37.1	35.0
SCConv-R50	**16.78/41.36**	**55.1**	**38.2**	**35.6**

对于 PASCAL VOC 数据集，如表 4 所示，采用 SCConv-R50 和 SCConv-R101 的 RetinaNet 的 AP@[.5] 分别为 78.68% 和 80.36%，相比原始 ResNet50 和 ResNet101 分别高出 0.8% 和 1.1%，同时将参数量和 FLOPs 减少 34.1% 和 37%。对于 MS COCO 数据集，如表 5 所示，采用 SCConv-R50 的 RetinaNet 的 AP@[.5] 为 55.1%，相比原始 ResNet-50 高出 0.9%，同时减少超过 22G FLOPs。此外，我们的方法在两个数据集上均持续优于当前最先进方法。例如，在 PASCAL VOC 和 MS COCO 数据集上，SCConv-R50 的 mAP@[.5,.95] 分别比 SlimConv-R50 高出近 0.8% 和 0.6%。简言之，这些结果证明 SCConv 模块不仅带来性能提升，还帮助网络以更少的参数量学习到更具代表性的特征，从而使目标检测能够部署在资源受限的设备上。

4. 结论

本文提出了一种新颖的空间与通道重构模块（SCConv），这是一种高效的架构单元，通过减少标准卷积中广泛存在的空间与通道冗余，在降低计算成本和模型存储的同时提升 CNN 模型的性能。我们通过两个各具特色的模块——SRU 与 CRU——来削减特征图中的冗余，在大幅削减计算量的同时取得可观的性能提升。此外，SCConv 是一个即插即用模块，可在不调整任何模型架构的情况下通用地替换标准卷积。再者，在图像分类与目标检测上与各种 SOTA 方法的大量实验表明，嵌入 SCConv 的模型在性能与模型效率之间取得了更优的权衡。最后，我们希望所提出的方法能为更高效的架构设计研究带来启发。

致谢。 本研究受以下项目部分资助：国家重点研发计划“2030”项目（2018AAA0100500）、国家自然科学基金（62273150, 62171323）、上海市自然科学基金（22ZR1421000）、上海市杰出学术带头人计划（21XD1430600）、上海市科学技术委员会（22DZ2229004）。

参考文献

[1] Jierun Chen, Tianlang He, Weipeng Zhuo, Li Ma, Sangtae Ha, and S-H Gary Chan. *Tvconv*：面向布局感知视觉处理的高效平移变体卷积. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pages 12548–12558, 2022.

[2] Yinpeng Chen, Xiyang Dai, Dongdong Chen, Mengchen Liu, Xiaoyi Dong, Lu Yuan, and Zicheng Liu. *MobileFormer*：连接 *MobileNet* 与 *Transformer*. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pages 5270–5279, 2022.

[3] Yunpeng Chen, Haoqi Fan, Bing Xu, Zhicheng Yan, Yannis Kalantidis, Marcus Rohrbach, Shuicheng Yan, and Jiashi Feng. 丢弃一个八度：用八度卷积减少卷积神经网络中的空间冗余. In Proceedings of the IEEE/CVF International Conference on Computer Vision, pages 3435–3444, 2019.

[4] François Chollet. *Xception*：基于深度可分离卷积的深度学习. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, pages 1251–1258, 2017.

[5] Emily L Denton, Wojciech Zaremba, Joan Bruna, Yann LeCun, and Rob Fergus. 利用卷积网络内部的线性结构实现高效评估. Advances in Neural Information Processing Systems, 27, 2014.

[6] Mark Everingham, Luc Van Gool, C. K. I. Williams, John Winn, and A. Zisserman. *PASCAL* 视觉目标类别挑战赛 *2007*（*VOC2007*）结果， 2007.

[7] Dongyoon Han, Young Joon Yoo, Beomyoung Kim, and Byeongho Heo. 用无参数层学习特征. arXiv preprint arXiv:2202.02777, 2022.

[8] Kai Han, Yunhe Wang, Qi Tian, Jianyuan Guo, Chunjing Xu, and Chang Xu. *GhostNet*：以廉价运算获得更多特征. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pages 1580–1589, 2020.

[9] Song Han, Huizi Mao, and William J Dally. 深度压缩：通过剪枝、训练量化与哈夫曼编码压缩深度神经网络. arXiv preprint arXiv:1510.00149, 2015.

[10] Kaiming He, Xiangyu Zhang, Shaoqing Ren, and Jian Sun. 用于图像识别的深度残差学习. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, pages 770–778, 2016.

[11] Geoffrey Hinton, Oriol Vinyals, Jeff Dean, et al. 在神经网络中蒸馏知识. arXiv preprint arXiv:1503.02531, 2(7), 2015.

[12] Andrew G Howard, Menglong Zhu, Bo Chen, Dmitry Kalenichenko, Weijun Wang, Tobias Weyand, Marco Andreetto, and Hartwig Adam. *MobileNets*：面向移动视觉应用的高效卷积神经网络. arXiv preprint arXiv:1704.04861, 2017.

[13] Andrew G Howard, Menglong Zhu, Bo Chen, Dmitry Kalenichenko, Weijun Wang, Tobias Weyand, Marco Andreetto, and Hartwig Adam. *MobileNets*：面向移动视觉应用的高效卷积神经网络. In Computer Vision and Pattern Recognition, 2017.

[14] Gao Huang, Zhuang Liu, Laurens Van Der Maaten, and Kilian Q Weinberger. 稠密连接的卷积网络. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, pages 4700–4708, 2017.

[15] Alex Krizhevsky. 从 *Tiny Images* 学习多层特征. Technical report, University of Toronto, 2009.

[16] Alex Krizhevsky, Ilya Sutskever, and Geoffrey E Hinton. 用深度卷积神经网络进行 *ImageNet* 分类. In Neural Information Processing Systems, pages 1097–1105, 2012.

[17] Hao Li, Asim Kadav, Igor Durdanovic, Hanan Samet, and Hans Peter Graf. 剪枝滤波器以得到高效卷积网络. arXiv preprint arXiv:1608.08710, 2016.

[18] Xiang Li, Wenhai Wang, Xiaolin Hu, and Jian Yang. 选择性核网络. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pages 510–519, 2019.

[19] Yunsheng Li, Yinpeng Chen, Xiyang Dai, Dongdong Chen, Mengchen Liu, Lu Yuan, Zicheng Liu, Lei Zhang, and Nuno Vasconcelos. *MicroNet*：以极低 *FLOPs* 改进图像识别. In Proceedings of the IEEE/CVF International Conference on Computer Vision, pages 468–477, 2021.

[20] Tsung-Yi Lin, Priya Goyal, Ross Girshick, Kaiming He, and Piotr Dollár. 用于稠密目标检测的 *Focal Loss*. In Proceedings of the IEEE International Conference on Computer Vision, pages 2980–2988, 2017.

[21] Tsung Yi Lin, Michael Maire, Serge Belongie, James Hays, Pietro Perona, Deva Ramanan, Piotr Dollár, and C Lawrence Zitnick. *Microsoft COCO*：上下文中的常见物体. In European Conference on Computer Vision, pages 740–755, 2014.

[22] Zhuang Liu, Jianguo Li, Zhiqiang Shen, Gao Huang, Shoumeng Yan, and Changshui Zhang. 通过网络瘦身学习高效卷积网络. In Proceedings of the IEEE International Conference on Computer Vision, pages 2736–2744, 2017.

[23] Jiaxiong Qiu, Cai Chen, Shuaicheng Liu, Heng-Yu Zhang, and Bing Zeng. *SlimConv*：通过特征重组减少卷积神经网络中的通道冗余. IEEE Transactions on Image Processing, 30:6434–6445, 2021.

[24] Olga Russakovsky, Jia Deng, Hao Su, Jonathan Krause, Sanjeev Satheesh, Sean Ma, Zhiheng Huang, Andrej Karpathy, Aditya Khosla, Michael Bernstein, et al. *ImageNet* 大规模视觉识别挑战赛. International Journal of Computer Vision, 115(3):211–252, 2015.

[25] Pravendra Singh, Vinay Kumar Verma, Piyush Rai, and Vinay P Namboodiri. *HetConv*：面向深度 *CNN* 的基于异构卷积核的卷积. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pages 4835–4844, 2019.

[26] Xinglong Sun, Ali Hassani, Zhangyang Wang, Gao Huang, and Humphrey Shi. *Disperse*：面向多任务模型压缩的解耦稀疏化. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pages 12382–12392, 2022.

[27] Mingxing Tan and Quoc Le. *EfficientNet*：重新思考卷积神经网络的模型缩放. In International Conference on Machine Learning, pages 6105–6114. PMLR, 2019.

[28] Xudong Wang and X Yu Stella. *Tied Block* 卷积：用共享的更薄滤波器构建更精简更优秀的 *CNN*. In Proceedings of the AAAI Conference on Artificial Intelligence, volume 35, pages 10227–10235, 2021.

[29] Yuxin Wu and Kaiming He. 分组归一化. In Proceedings of the European Conference on Computer Vision (ECCV), pages 3–19, 2018.

[30] Mengzhou Xia, Zexuan Zhong, and Danqi Chen. 结构化剪枝学习紧凑而精确的模型. arXiv preprint arXiv:2204.00408, 2022.

[31] Saining Xie, Ross Girshick, Piotr Dollár, Zhuowen Tu, and Kaiming He. 面向深度神经网络的聚合残差变换. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, pages 1492–1500, 2017.

[32] Qiulin Zhang, Zhuqing Jiang, Qishuo Lu, Jia'nan Han, Zhengxin Zeng, Shang-Hua Gao, and Aidong Men. *Split to be Slim*：普通卷积中被忽视的冗余. arXiv preprint arXiv:2006.12085, 2020.

[33] Xiangyu Zhang, Xinyu Zhou, Mengxiao Lin, and Jian Sun. *ShuffleNet*：面向移动设备的极致高效卷积神经网络. In Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition, pages 6848–6856, 2018.

[34] Borui Zhao, Quan Cui, Renjie Song, Yiyu Qiu, and Jiajun Liang. 解耦的知识蒸馏. In Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition, pages 11953–11962, 2022.

[35] Daquan Zhou, Qibin Hou, Yunpeng Chen, Jiashi Feng, and Shuicheng Yan. 重新思考瓶颈结构以实现高效的移动网络设计. In European Conference on Computer Vision, pages 680–697. Springer, 2020.